

# Curso 2 – CD, AM e DM

# IA BIG ATA

### Mineração de Dados


Parte 4
Extração de Padrões
Agrupamento Particional


Prof. Ricardo M. Marcacini ricardo.marcacini@icmc.usp.br

### Métodos para Agrupamento de Dados



- Particionais: organizar dados em uma partição de *k clusters*
- Hierárquicos: organizar dados em uma decomposição hierárquica de clusters e subclusters



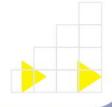


### **Agrupamento Particional**



- Falaremos sobre métodos de agrupamento para obter partições rígidas dos dados
- Partição rígida: clusters não possuem sobreposição
  - Dado um conjunto de *n* objetos

$$\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \cdots, \mathbf{x}_n\}$$



### **Agrupamento Particional**




- Falaremos sobre métodos de agrupamento para obter partições rígidas dos dados
- Partição rígida: clusters não possuem sobreposição
  - Dado um conjunto de *n* objetos

$$\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \cdots, \mathbf{x}_n\}$$

Obter um agrupamento C em k clusters

$$C = \{C_1, C_2, \cdots, C_k\}$$
$$C_1 \cup C_2 \cup \cdots \cup C_k = \mathbf{X}$$



### **Agrupamento Particional**



- Falaremos sobre métodos de agrupamento para obter partições rígidas dos dados
- Partição rígida: clusters não possuem sobreposição
  - Dado um conjunto de *n* objetos

$$\mathbf{X} = \{\mathbf{x}_1, \mathbf{x}_2, \cdots, \mathbf{x}_n\}$$


Obter um agrupamento C em k clusters

$$C = \{C_1, C_2, \cdots, C_k\}$$
$$C_1 \cup C_2 \cup \cdots \cup C_k = \mathbf{X}$$

Sem clusters vazios e sem sobreposição

$$C_i \neq \emptyset$$

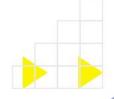
$$C_i \cap C_j = \emptyset \text{ para } i \neq j$$



### Algoritmo k-Médias ou k-Means

IVIBA IA BIG DAYA

- Amplamente usado na indústria e academia
- Características desejáveis para Mineração de Dados
  - Simplicidade
  - Interpretabilidade
  - Eficiência Computacional




### Algoritmo k-Médias ou k-Means


MBA NA BIG DAYA

- Amplamente usado na indústria e academia
- Características desejáveis para Mineração de Dados
  - Simplicidade
  - Interpretabilidade
  - Eficiência Computacional

Vamos começar a estudar o *k-Means* a partir de um exemplo didático...






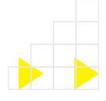






Primeiro passo é definir o número *k* de *clusters* que se deseja encontrar






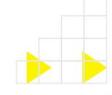


Primeiro passo é definir o número k de clusters que se deseja encontrar

Vamos definir k=3








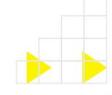


Com k=3, nós vamos inicializar *k* centroides.

Cada centroide é um ponto e representa um cluster.

Inicialização aleatória de centroides.









Com k=3, nós vamos inicializar *k* centroides.

Cada centroide é um ponto e representa um cluster.


Inicialização aleatória de centroides.







MBA IA BIGA DAYA


Agora, nós associamos cada objeto ao centróide mais próximo.

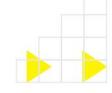




Agora, nós associamos cada objeto ao centróide mais próximo.











Agora, nós atualizamos o centroide de cada cluster.

O centroide é calculado como o vetor médio do cluster.









Agora, nós atualizamos o centroide de cada cluster.

O centroide é calculado como o vetor médio do cluster.









Agora, nós atualizamos o centroide de cada cluster.

O centroide é calculado como o vetor médio do cluster.

Confira os novos centroides obtidos.




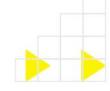




#### Repetir até convergir:

- Alocar objetos ao centróide mais próximo
- Atualizar centroides






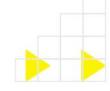


#### Repetir até convergir:

- Alocar objetos ao centróide mais próximo
- Atualizar centroides




Atributo #1





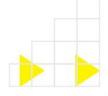
#### Algoritmo:

- Selecionar k centroides iniciais
- 2. Repetir até convergir:
  - 2.1. Formar k clusters atribuindo cada objeto ao centroide mais próximo
  - 2.2. Atualizar o centroide de cada cluster



Atributo #1

Critérios de convergência: (1) poucas mudanças nos clusters/centroides; (2) número máximo de iterações.







- Apropriado para dados contínuos
- O cálculo da média faz sentido para seus dados?
- Medidas de proximidade para dados contínuos
  - Exemplo: distância euclidiana e dissimilaridade de cosseno
- Converge em poucas iterações


Em geral, os centroides iniciais são escolhidos aleatoriamente.


Clusters podem diferentes em cada execução do k-means.


































































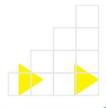





























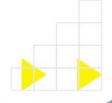





















Nesta inicialização de centroides, o *k-means* obteve uma <u>partição sub-ótima</u>.












- Importância da escolha dos centroides iniciais
- Soluções comuns:
  - Múltiplas execuções do k-means e escolher a "melhor" solução de agrupamento (minimizar erro quadrático E)

$$E = \sum_{i=1}^{k} \sum_{\mathbf{x} \in \mathbf{C}_i} d^2(\mu_i, \mathbf{x})$$






- Importância da escolha dos centroides iniciais
- Soluções comuns:
  - Múltiplas execuções do k-means e escolher a "melhor" solução de agrupamento (minimizar erro quadrático E)

$$E = \sum_{i=1}^{k} \sum_{\mathbf{x} \in \mathbf{C_i}} d^2(\mu_i, \mathbf{x})$$

- Seleção "informada" dos centroides:
  - Garantir que sejam distantes entre si
  - Analista pode indicar centroides considerando sua experiência sobre o domínio dos dados






- Limitações do *k-Means* 
  - Outliers
  - Clusters de tamanhos muito diferentes
  - Clusters de densidades muito diferentes
  - Clusters de formatos não globulares




MBA IA BIG DAYA

- Limitações do *k-Means:* 
  - Clusters de <u>tamanhos</u> muito diferentes






- Limitações do k-Means:
  - Clusters de <u>densidades</u> muito diferentes




MBA IA BIG DATA


- Limitações do *k-Means:* 
  - Clusters de <u>formatos</u> não globulares

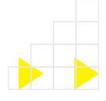


MBA IA BIG DATA

- Mitigando as limitações do k-Means:
  - Podemos aumentar o número de clusters










#### Algoritmo k-Medóides:

- Similar ao k-Means
- São utilizados medoides no lugar de centroides
  - Medoides são objetos reais do conjunto de dados
  - Medoides representam objetos centrais do cluster
  - Não são calculados vetores médios
- Podemos usar apenas a matriz de dissimilaridades

#### Matriz atributo-valor

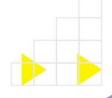
$$\mathbf{X} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1d} \\ x_{21} & x_{22} & \cdots & x_{2d} \\ \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{nd} \end{bmatrix}$$

Aplicar medida de proximidade



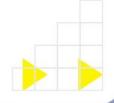
#### Matriz dissimilaridades

$$\mathbf{M} = \begin{bmatrix} d_{11} & d_{12} & \cdots & d_{1n} \\ d_{21} & d_{22} & \cdots & d_{2n} \\ \vdots & & \ddots & \vdots \\ d_{n1} & d_{n2} & \cdots & d_{nn} \end{bmatrix}$$





- Usa o k-Means para produzir um agrupamento hierárquico
- Inicialmente, agrupar os dados com k=2
- Escolher o maior cluster e repetir o agrupamento com k=2
- Repetir até que obter a quantidade desejada de cluster



## Agrupamento Hierárquico




Dois métodos clássicos para agrupamento hierárquico

#### **Aglomerativos:**

- → Iniciar alocando cada objeto em um *cluster*
- → Encontrar o melhor par de clusters para unir
- → Repetir até formar um único *cluster*


#### **Divisivos:**

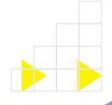
- → Iniciar alocando todos os objetos em um único cluster
- → Dividir um *cluster* em dois subclusters
- → Repetir a divisão até que cada objeto seja um *cluster*






- Usa o k-Means para produzir um agrupamento hierárquico
- Inicialmente, agrupar os dados com k=2
- Escolher o maior cluster e repetir o agrupamento com k=2
- Repetir até que obter a quantidade desejada de cluster

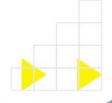







- Usa o k-Means para produzir um agrupamento hierárquico
- Inicialmente, agrupar os dados com k=2
- Escolher o maior cluster e repetir o agrupamento com k=2
- Repetir até que obter a quantidade desejada de cluster

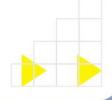







- Usa o k-Means para produzir um agrupamento hierárquico
- Inicialmente, agrupar os dados com k=2
- Escolher o maior cluster e repetir o agrupamento com k=2
- Repetir até que obter a quantidade desejada de cluster








- Usa o k-Means para produzir um agrupamento hierárquico
- Inicialmente, agrupar os dados com k=2
- Escolher o maior cluster e repetir o agrupamento com k=2
- Repetir até que obter a quantidade desejada de cluster






### Métodos para Agrupamento de Dados

MBA BIG DAFA

- Estudamos diferentes métodos e algoritmos
- Qual solução de agrupamento escolher?
- Qual o número apropriado de clusters para meus dados?




## Métodos para Agrupamento de Dados

IVIBA IA BIG DAYA

- Estudamos diferentes métodos e algoritmos
- Qual solução de agrupamento escolher?
- Qual o número apropriado de clusters para meus dados?

#### Próxima aula

Validação de Agrupamentos







Rezende, S. O. (2003). Sistemas inteligentes: fundamentos e aplicações. Editora Manole Ltda.

Tan, P.N.; Steinbach, M.; Karpatne, A.; Kumar, V. (2016). *Introduction to Data Mining (2nd Edition)*. Pearson.

#### Agradecimentos:

Notas de aula do curso de Análise de Agrupamentos, Prof. Eduardo Hruschka. Programa de Pós-Graduação do ICMC/USP. 2012.